RINGKASAN EKSEKUTIF TUGAS BESAR 1 JST

Klasifikasi Risiko Penyakit Jantung (Heart Failure) Menggunakan Perceptron & ADALINE Berbasis NumPy

MATA KULIAH	INSTITUSI	TIM PENYUSUN	DATASET
JST (IT6053)	**FTI UKDW**	**Kelompok 15**	**Heart Failure (918)**

1. RINGKASAN KASUS & PROBLEMATIKA KLINIS

Penyakit kardiovaskular merupakan penyebab utama kematian secara global. Penelitian ini memformulasikan sistem deteksi dini risiko penyakit jantung sebagai permasalahan **klasifikasi biner terawasi (supervised binary classification)**. Target medis dipetakan menjadi dua kelas bipolar: pasien terdiagnosis berisiko tinggi (**y = +1**, 508 sampel) dan pasien kondisi normal (**y = −1**, 410 sampel).

Dataset fisik `dataset.csv` memuat 918 sampel pasien tanpa nilai hilang (missing values). Berkas diproses melalui transformasi *One-Hot Encoding* pada 5 fitur kategorikal (*Sex, ChestPainType, RestingECG, ExerciseAngina, ST_Slope*), menghasilkan matriks input berdimensi 15 fitur numerik (x_1 hingga x_{15}). Data dibagi secara terstratifikasi (**80% Train / 20% Test**) dengan random seed 42 untuk menjamin konsistensi evaluasi.

2. METODOLOGI & FORMULASI ARSITEKTUR JARINGAN

Dua model jaringan syaraf tiruan lapis tunggal (single-layer neural networks) diimplementasikan dari nol menggunakan pustaka NumPy murni:

- **Perceptron (Rosenblatt, 1958):** Menggunakan fungsi aktivasi undak biner (*Hard Limit Step Function*). Pembaruan parameter dilakukan secara diskret berdasarkan sinyal kesalahan klafikasi: $\Delta w_j = \eta\ (y - \hat{y})\ x_j$, dengan $\hat{y} \in \{-1, +1\}$.
- **ADALINE - Adaptive Linear Neuron (Widrow & Hoff, 1960):** Menggunakan fungsi aktivasi linier kontinu $z = \mathbf{w}^T \mathbf{x} + b$ pada fase pembelajaran, dengan meminimalkan fungsi kerugian Kuadrat Terkecil (MSE): $J(\mathbf{w}, b) = (1 / 2N) \sum (y^{(i)} - z^{(i)})^2$ melalui algoritma *Batch Gradient Descent*.

Sinyal Eror Perceptron

$\mathbf{e = (y - \hat{y}) \in \{-2, 0, 2\}}$

Pembaruan diskret hanya terjadi saat terjadi kesalahan klasifikasi akhir pada sampel.

Sinyal Eror ADALINE

$\mathbf{e = (y - z) \in \mathbb{R}}$

Pembaruan kontinu berdasarkan jarak kuadrat linier respon terhadap target nyata.

Standardisasi Skala

$\mathbf{x_{std} = (x - \mu) / \sigma}$

Dihitung khusus pada data latih untuk mencegah kebocoran data (data leakage).

3. DESAIN EKSPERIMEN & HASIL UTAMA

Sebanyak 8 konfigurasi eksperimen (Run 1–8) dijalankan selama 50 epoch pada data latih (N=734) dan dievaluasi secara independen pada data uji (N=184) untuk menguji pengaruh laju pembelajaran (η) dan standardisasi fitur Z-score:

Run	Model	Eta (η)	Std	Akurasi Train	Akurasi Test	Precision	Recall	F1-Score	Error / Loss Akhir
Run 1	Perceptron	0.001	Ya	82.97%	79.89%	78.26%	88.24%	82.95%	152 misclass
Run 2	Perceptron	0.010	Ya	82.97%	79.89%	78.26%	88.24%	82.95%	152 misclass
Run 3	Perceptron	0.100	Ya	82.97%	79.89%	78.26%	88.24%	82.95%	152 misclass
Run 4	ADALINE	0.001	Ya	85.42%	86.96%	91.49%	84.31%	87.76%	J = 0.4248
Run 5	ADALINE	0.010	Ya	85.69%	88.04%	91.67%	86.27%	88.89%	J = 0.2335
Run 6	**ADALINE**	**0.100**	**Ya**	**86.10%**	**89.13%**	**87.96%**	**93.14%**	**90.48%**	**J = 0.2096**
Run 7	Perceptron	0.010	Tidak	54.50%	55.98%	92.00%	22.55%	36.22%	282 misclass
Run 8	ADALINE	0.010	Tidak	44.69%	44.57%	0.00%	0.00%	0.00%	Loss Exploded (NaN)

4. KETERBATASAN MODEL & ANALISIS AKADEMIK

- **Ketidakterpisahan Linier (Non-Linear Separability):** Kurva riwayat pelatihan Perceptron pada data terstandardisasi berosilasi stabil pada kisaran 140–150 kesalahan per epoch tanpa pernah mencapai nol. Ini membuktikan secara matematis bahwa batas keputusan linier hiperbidang tidak mampu memisahkan kelas penyakit jantung secara sempurna.
- **Invariansi Laju Pembelajaran Perceptron:** Pada inisialisasi bobot nol, variasi η (0.001, 0.01, 0.1) tidak mengubah performa Perceptron (semuanya 79.89%). Hal ini terjadi karena η hanya menskalakan besaran magnitudo vektor bobot **w** tanpa mengubah arah sudut bidang pemisah.
- **Ledakan Gradien ADALINE (Gradient Explosion):** Tanpa standardisasi Z-score (Run 8), rentang nilai fitur yang sangat bervariasi (misal: *Cholesterol* vs *Oldpeak*) menyebabkan permukaan fungsi kerugian menjadi sangat curam. Vektor gradien meloncat melebihi minimum lokal sehingga nilai loss bernilai `NaN`.

5. KESIMPULAN & REKOMENDASI KLINIS

> **Model Terbaik: ADALINE Terstandardisasi (Run 6, η = 0.1)**
> ADALINE dengan η = 0.1 pada data terstandardisasi mencapai performa tertinggi dengan **Akurasi Uji 89.13%**, **Recall 93.14%**, dan **F1-Score 90.48%**. Dalam konteks medis, tingginya nilai Recall sangat krusial untuk meminimalkan risiko *False Negative* (pasien sakit yang terprediksi normal). Standardisasi fitur terbukti merupakan syarat mutlak bagi konvergensi model berbasis gradien kontinu.