LAPORAN TUGAS BESAR 1 (TB1)
JARINGAN SYARAF TIRUAN (IT6053)

Analisis dan Implementasi Klasifikasi Risiko Penyakit Jantung (Heart Failure) Menggunakan Model Perceptron dan ADALINE Berbasis Python dan NumPy

Nama Repository GitHub	TB1-JST-KelompokXX
Program Studi / Kelas	Informatika / IT6053 - Kelas A
Mata Kuliah / SKS	Jaringan Syaraf Tiruan (3 SKS) - UKDW
Identitas Kelompok	1. Drestanta Dipta Jalu Prakasya - NIM: 71220895 2. Josua Adriansyah F.n - NIM: 71220878

1. MASALAH DAN TUJUAN ANALISIS

Penyakit kardiovaskular (Cardiovascular Diseases / CVDs) merupakan penyebab utama kematian secara global. Diagnosis dini terhadap tingkat risiko penyakit jantung (heart failure) menjadi langkah krusial dalam pencegahan komplikasi medis yang fatal. Dalam bidang pembelajaran mesin terawasi (supervised learning), identifikasi risiko medis ini diformulasikan sebagai permasalahan klasifikasi biner terawasi (supervised binary classification).

Formulasi pemetaan linier JST bertujuan untuk memetakan vektor masukan atribut medis $x \in R^{15}$ ke dalam variabel target diskret $y \in \{-1, +1\}$:

• Kelas -1 (Negatif): Pasien kondisi Normal / Tidak Terdiagnosa Penyakit Jantung.

• Kelas +1 (Positif): Pasien Berisiko / Terdiagnosa Penyakit Jantung (Heart Disease).

Tujuan Analisis:

1. Mengembangkan model Perceptron (Rosenblatt, 1958) dan ADALINE (Widrow & Hoff, 1960) secara mandiri dari nol (from scratch) menggunakan bahasa pemrograman Python dan pustaka komputasi numerik NumPy.

2. Membandingkan mekanisme pembelajaran diskret berbasis kesalahan klasifikasi (misclassification-based error) pada Perceptron dengan pembaruan gradien linier kontinu (gradient descent on continuous linear error) pada ADALINE.

3. Menganalisis secara teoretis dan empiris dampak dari skala fitur (standardization), laju pembelajaran (learning rate η), dan jumlah epoch terhadap kestabilan konvergensi, fenomena gradient explosion, serta kemampuan generalisasi model.

4. Mengevaluasi sifat keterpisahan linier (linear separability) dari Heart Failure Prediction Dataset berdasarkan perilaku linimasa pelatihan.

2. DATASET SERTA KAITANNYA DENGAN TUGAS 1

Laporan ini melanjutkan analisis kasus dari Tugas 1, di mana Heart Failure Prediction Dataset dari platform Kaggle telah diidentifikasi karakteristik dasarnya.

2.1 Deskripsi dan Mutu Dataset

• Sumber Dataset: Kaggle — Heart Failure Prediction Dataset (heart.csv).

• Ukuran Sampel: 918 observasi pasien.

• Audit Kualitas Data: 0 missing values dan 0 observasi ganda/duplikat.

• Distribusi Kelas Target (HeartDisease):

- Kelas +1 (Heart Disease): 508 sampel (55,34%)
- Kelas -1 (Normal): 410 sampel (44,66%)

2.2 Transformasi Fitur (One-Hot Encoding)

Dataset awal memuat 11 fitur medis (campuran numerik dan kategorikal). Seluruh fitur kategorikal diubah menjadi biner numerik menggunakan teknik One-Hot Encoding (pd.get_dummies(drop_first=True)), menghasilkan 15 fitur input numerik (x1, x2, ..., x15):

Nama Fitur (X)	Tipe Data Awal	Transformasi Encoding / Deskripsi
Age	Numerik	Usia pasien dalam tahun
RestingBP	Numerik	Tekanan darah istirahat (mm Hg)
Cholesterol	Numerik	Kolesterol serum (mm/dl)
FastingBS	Biner	Gula darah puasa > 120 mg/dl (1: Ya, 0: Tidak)
MaxHR	Numerik	Detak jantung maksimum yang dicapai
Oldpeak	Numerik	Depresi ST hasil tes beban olahraga
Sex_M	Kategorikal	Dummy biner (1: Laki-laki, 0: Perempuan)
ChestPainType_ATA	Kategorikal	Dummy biner Atypical Angina
ChestPainType_NAP	Kategorikal	Dummy biner Non-Anginal Pain
ChestPainType_TA	Kategorikal	Dummy biner Typical Angina
RestingECG_Normal	Kategorikal	Dummy biner EKG Istirahat Normal
RestingECG_ST	Kategorikal	Dummy biner EKG Istirahat ST-T Abnormal
ExerciseAngina_Y	Kategorikal	Dummy biner Angina Terinduksi Olahraga (1: Ya, 0: Tidak)
ST_Slope_Flat	Kategorikal	Dummy biner Kemiringan Segmen ST Datar
ST_Slope_Up	Kategorikal	Dummy biner Kemiringan Segmen ST Naik

3. ARTIKEL DAN KODE PENDUKUNG

Metodologi dan arsitektur eksperimen dibangun berdasarkan tiga rujukan ilmiah dan teknis utama:

1. Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65(6), 386–408.

    - Kontribusi: Dasar teori model neuron tunggal Perceptron dan aturan pembaruan bobot linier berbasis sinyal kesalahan klasifikasi diskret.

2. Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. IRE WESCON Convention Record, Part 4, 96–104.

    - Kontribusi: Arsitektur ADALINE (Adaptive Linear Element), fungsi kerugian Mean Squared Error (MSE), dan formulasi Delta Rule / Least Mean Squares (LMS) mengoptimalkan parameter via Batch Gradient Descent.

3. Raschka, S. (2015). Single-Layer Neural Networks and Gradient Descent. MLxtend Documentation.

    - Kontribusi Adaptasi Kode: Acuan struktur Pemrograman Berorientasi Objek (OOP) pada Python/NumPy untuk merepresentasikan kelas PerceptronNumPy dan AdalineNumPy serta pencatatan histori pelatihan.

4. MODEL NEURON DAN ATURAN PEMBELAJARAN

Kedua model mengevaluasi kombinasi linier masukan yang sama (linear aggregator):

$z = w^T x + b = \Sigma_{i=1}^{15} (w_i * x_i) + b$

Fungsi ambang keputusan biner bipolar (sign) didefinisikan sebagai:

$y_hat = \varphi(z) = +1$ jika $z \geq 0$, dan -1 jika $z < 0$.

4.1 Perceptron (Sequential Update)

Perceptron memperbarui bobot dan bias secara individual (sample-by-sample) hanya ketika terjadi kesalahan prediksi ($y_hat \neq y$):

$\Delta = \eta * (y - y_hat)$

$w \leftarrow w + \Delta * x, \quad b \leftarrow b + \Delta$

Pencatatan: Menghitung akumulasi jumlah sampel yang salah diklasifikasikan pada setiap epoch.

4.2 ADALINE (Batch Gradient Descent)

ADALINE menggunakan sinyal respon linier kontinu z sebelum fungsi aktivasi untuk menghitung error $e_i = y_i - z_i$.

Fungsi kerugian terkuadrat setengah (Half Mean Squared Error) didefinisikan sebagai:

$J(w, b) = (1 / 2n) * \Sigma_{i=1}^{n} (y_i - z_i)^2$

Aturan pembaruan parameter menggunakan Batch Gradient Descent:

$w \leftarrow w + \eta * (1 / n) * X^T e$

$b \leftarrow b + \eta * \text{mean}(e)$

Catatan: Ambang batas diskret $\varphi(z)$ hanya diterapkan pada tahap evaluasi/prediksi.

5. PENYIAPAN DATA SERTA RANCANGAN EKSPERIMEN

5.1 Pembagian Data dan Standardisasi Bebas Leakage

1. Stratified Split (80:20): Data dibagi secara terstratifikasi (random_state=42):
   - Data Latih (D_train): 734 sampel (406 positif +1, 328 negatif -1).
   - Data Uji (D_test): 184 sampel (102 positif +1, 82 negatif -1).
2. Standardisasi Bebas Kebocoran Data (No Data Leakage):

   Rata-rata (μ_train) dan deviasi standar (σ_train) dihitung hanya dari data latih, kemudian digunakan untuk mentransformasikan data latih dan data uji:

   $X_{train_std} = (X_{train} - \mu_{train}) / \sigma_{train}$

   $X_{test_std} = (X_{test} - \mu_{train}) / \sigma_{train}$

5.2 Matriks Rancangan Eksperimen (8 Runs Utama)

Delapan konfigurasi eksperimen dijalankan selama 50 epoch dengan inisialisasi bobot nol ($w = 0, b = 0$):

Run ID	Model	Learning Rate (η)	Epochs	Standardisasi Z-Score
Run 1	Perceptron	0,001	50	Ya (Terstandardisasi)
Run 2	Perceptron	0,010	50	Ya (Terstandardisasi)
Run 3	Perceptron	0,100	50	Ya (Terstandardisasi)
Run 4	ADALINE	0,001	50	Ya (Terstandardisasi)
Run 5	ADALINE	0,010	50	Ya (Terstandardisasi)
Run 6	ADALINE	0,100	50	Ya (Terstandardisasi)
Run 7	Perceptron	0,010	50	Tidak (Fitur Mentah / Raw)

Run 8	ADALINE	0,010	50	Tidak (Fitur Mentah / Raw)

6. HASIL EKSPERIMEN

6.1 Tabel Evaluasi Performa 8 Konfigurasi Pelatihan

Run ID	Model	η	Std	Acc Latih	Acc Uji	Prec (+1)	Rec (+1)	F1 (+1)	Loss/ Misclass
Run 1	Perceptron	0,001	Ya	82,97%	79,89%	78,26%	88,24%	82,95%	152 misclass
Run 2	Perceptron	0,010	Ya	82,97%	79,89%	78,26%	88,24%	82,95%	152 misclass
Run 3	Perceptron	0,100	Ya	82,97%	79,89%	78,26%	88,24%	82,95%	152 misclass
Run 4	ADALINE	0,001	Ya	85,42%	86,96%	91,49%	84,31%	87,76%	J = 0,4248
Run 5	ADALINE	0,010	Ya	85,69%	88,04%	91,67%	86,27%	88,89%	J = 0,2335
Run 6	**ADALINE**	**0,100**	**Ya**	**86,10 %**	**89,13 %**	**87,96 %**	**93,14 %**	**90,48 %**	**J = 0,2096**
Run 7	Perceptron	0,010	Tidak	54,50%	55,98%	92,00%	22,55%	36,22%	282 misclass
Run 8	ADALINE	0,010	Tidak	44,69%	44,57%	0,00%	0,00%	0,00%	Exploded (NaN)

6.2 Confusion Matrix Evaluasi pada Data Uji (D_test, N=184)

1. Perceptron Terstandardisasi (Run 1, 2, 3):

[TN = 57 , FP = 25]

[FN = 12 , TP = 90]

2. ADALINE Optimal (Run 6: η=0.1, Terstandardisasi):

[TN = 69 , FP = 13]

[FN = 7 , TP = 95]

3. ADALINE Tanpa Standardisasi (Run 8: Raw Data):

[TN = 82 , FP = 0]

[FN = 102, TP = 0]

6.3 Analisis Riwayat Kurva Pelatihan (Learning Curves)

A. Perceptron Misclassifications vs Epochs (Run 1 - 3, Standardized):

- Epoch 1: 210 misclassifications
- Epoch 10: 145 misclassifications
- Epoch 30: 158 misclassifications
- Epoch 50: 152 misclassifications

Perilaku: Osilasi terus-menerus pada rentang 135-155 kesalahan. Tidak pernah mencapai 0.

B. ADALINE Loss J(w,b) vs Epochs (Run 4 - 6, Standardized):

- Run 4 (η=0.001): Epoch 1 (0,5000) -> Epoch 50 (0,4248)
- Run 5 (η=0.01) : Epoch 1 (0,4950) -> Epoch 50 (0,2335)
- Run 6 (η=0.1) : Epoch 1 (0,4721) -> Epoch 50 (0,2096) -> Konvergen mulus sempurna.

7. PEMBAHASAN DAN KETERBATASAN

7.1 Analisis Keterpisahan Linier (Linear Separability)

Dataset Heart Failure secara definitif bersifat non-linearly separable (tidak dapat dipisahkan secara linier sempurna). Bukti-bukti empiris yang mendukung:

1. Kurva Perceptron berosilasi secara persisten pada kisaran 135 hingga 155 kesalahan per epoch.

2. Menurut Teorema Konvergensi Perceptron (Rosenblatt, 1958), Perceptron dijamin konvergen mencapai 0 kesalahan latih jika dan hanya jika data terpisah linier. Karena osilasi bertahan hingga epoch ke-50, data terbukti mengalami overlapping antar-kelas pada ruang fitur.

7.2 Invariansi Learning Rate pada Perceptron Berinisialisasi Nol

Pada Run 1, 2, dan 3, nilai η yang bervariasi (0,001; 0,01; 0,1) menghasilkan akurasi latih (82,97%) dan akurasi uji (79,89%) yang persis identik.

- Pembuktian Matematika:

Ketika bobot dan bias diinisialisasi dengan angka nol (w^(0) = 0, b^(0) = 0), persamaan pembaruan Perceptron bersifat skalar proporsional terhadap η:

$w^{(k)} = \eta * \Sigma_{(i \in misclass)} (y_i * x_i)$, $b^{(k)} = \eta * \Sigma_{(i \in misclass)} (y_i)$

• Besaran η hanya menskalakan magnitudo vektor bobot ||w|| tanpa mengubah arah sudut atau orientasi bidang batas keputusan (decision boundary hyperplane). Oleh karena itu, fungsi keputusan $sign(w^T x + b) = sign(\eta * (w_1^T x + b_1))$ menghasilkan urutan prediksi yang identik untuk seluruh $\eta > 0$.

7.3 Pengaruh Skala Fitur dan Fenomena Gradient Explosion

1. Penurunan Kinerja Perceptron Tanpa Standardisasi (Run 7): Akurasi uji merosot dari 79,89% menjadi 55,98%. Fitur dengan rentang nilai absolut besar seperti Cholesterol (~200) mendominasi nilai produk titik z, mengabaikan peran fitur biner kategorikal.

2. Ledakan Gradien ADALINE (Run 8): Tanpa standardisasi, gradien linier $X^T e$ menghasilkan nilai yang sangat besar. Langkah pembaruan bobot melompati titik minimum lokal fungsi kerugian, menyebabkan kerugian J(w, b) melonjak mendekati tak hingga (∞) hingga menghasilkan angka NaN (Not a Number). Akibatnya, seluruh prediksi runtuh menjadi kelas mayoritas tunggal (Recall = 0%).

7.4 Perbandingan Perceptron vs ADALINE

• Perceptron: Rentan terhadap osilasi pada data non-linearly separable karena sinyal pembaruan bersifat diskret ($y - \hat{y} \in \{-2, 0, 2\}$).

• ADALINE: Jauh lebih unggul dan stabil karena mengoptimalkan jarak linier kontinu (y - z) via Gradient Descent. Model ADALINE Best Run (Run 6) mencapai Recall 93,14%, yang sangat krusial dalam domain medis untuk meminimalkan risiko pasien berpenyakit jantung yang tidak terdeteksi (False Negative).

7.5 Keterbatasan Model & Arah Pengembangan

• Keterbatasan Arsitektur Single-Layer: Baik Perceptron maupun ADALINE hanya mampu membentuk bidang keputusan garis/hiperbidang linier lurus (15-dimensional hyperplane).

• Pengembangan Berikutnya: Diperlukan arsitektur Multi-Layer Perceptron (MLP) dengan hidden layer, fungsi aktivasi non-linier (ReLU/Sigmoid), dan algoritma Backpropagation untuk menangkap interaksi non-linier yang kompleks antar-indikator medis.

8. KESIMPULAN

Kesimpulan berikut disusun untuk menjawab secara langsung seluruh tujuan analisis yang dirumuskan di awal:

1. Formulasi Supervised Learning: Klasifikasi risiko penyakit jantung berbasis 15 fitur medis terstandardisasi berhasil diimplementasikan secara tepat menggunakan model Perceptron dan ADALINE berbasis NumPy mandiri.

2. Model Terbaik: Model ADALINE Terstandardisasi dengan $\eta = 0.1$ (Run 6) terbukti sebagai model terbaik, mencapai Akurasi Uji 89,13%, Precision 87,96%, Recall 93,14%, dan F1-Score 90,48%.

3. Mekanisme Pembelajaran: ADALINE terbukti lebih unggul dibanding Perceptron pada data non-linearly separable karena mengoptimalkan permukaan kerugian kontinu MSE secara mulus, sedangkan Perceptron berosilasi tanpa konvergensi.

4. Pentingnya Preprocessing: Standardisasi Z-score terbukti menjadi syarat mutlak untuk mencegah gradient explosion (pencapaian NaN) pada algoritma berbasis gradien linier seperti ADALINE.

9. DAFTAR PUSTAKA

1. Aggarwal, C. C. (2018). Neural Networks and Deep Learning: A Textbook. Springer.

2. da Silva, I. N., Spatti, D. H., Flauzino, R. A., Liboni, L. H. B., & dos Reis Alves, S. F. (2017). Artificial Neural Networks: A Practical Course. Springer.

3. Haykin, S. (2009). Neural Networks and Learning Machines (3rd ed.). Pearson.

4. Raschka, S. (2015). Single-Layer Neural Networks and Gradient Descent. MLxtend User Guide. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/

5. Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65(6), 386–408. https://doi.org/10.1037/h0042519

6. Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. IRE WESCON Convention Record, Part 4, 96–104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf

LAMPIRAN

LAMPIRAN A: PERHITUNGAN MANUAL LANGKAH PEMBELAJARAN

Inisialisasi Parameter Awal: w^(0) = 0_15, b^(0) = 0.0, η = 0,01.

A.1 Perceptron (2 Sampel Pertama Data Latih Terstandardisasi)

• Sampel 0 (i=0): Target y^(0) = +1

x^(0) = [0,970, 0,339, 0,127, 1,835, -0,325, 0,317, 0,517, 2,097, -0,517, -0,240, -1,248, 2,051, 1,203, 0,981, -0,862]

1. z^(0) = 0.0^T * x^(0) + 0.0 = 0,0000
2. y_hat^(0) = sign(0,0000) = +1
3. Δ^(0) = 0,01 * (1 - 1) = 0,0000 (Klasifikasi Benar)
4. w^(1) = 0_15, b^(1) = 0,0000

• Sampel 1 (i=1): Target y^(1) = -1

x^(1) = [0,122, -1,266, 0,099, 1,835, 1,690, -0,440, 0,517, 2,097, -0,517, -0,240, -1,248, 2,051, -0,831, -1,019, 1,160]

1. z^(1) = 0.0^T * x^(1) + 0.0 = 0,0000
2. y_hat^(1) = sign(0,0000) = +1 (Salah Klasifikasi)
3. Δ^(1) = 0,01 * (-1 - 1) = -0,0200
4. w^(2) = w^(1) + (-0,0200) * x^(1) = [-0,0024, 0,0253, -0,0020, -0,0367, -0,0338, 0,0088, -0,0103, -0,0419, 0,0103, 0,0048, 0,0250, -0,0410, 0,0166, 0,0204, -0,0232]

   b^(2) = b^(1) + (-0,0200) = -0,0200

A.2 ADALINE (2 Iterasi Batch Pertama, n=734, Data Latih Terstandardisasi)

Inisialisasi: w^(0) = 0_15, b^(0) = 0.0, η = 0,01.

• Iterasi Batch 1 (k=1):

1. Respon linier: z^(0) = X_train_std * 0 + 0 = 0_734
2. Vektor error: e^(0) = y_train - z^(0) = y_train
3. Loss Awal J^(0) = (1 / (2 * 734)) * Σ (y_i)^2 = 734 / (2 * 734) = 0,5000
4. Pembaruan bias: b^(1) = 0.0 + 0,01 * mean(y_train) = 0,01 * ((406 - 328) / 734) = +0,00106
5. Pembaruan bobot: w^(1) = 0 + (0,01 / 734) * X_train_std^T * y_train

• Iterasi Batch 2 (k=2):

1. Respon linier terbarui: z^(1) = X_train_std * w^(1) + b^(1)

2. Vektor error terbarui: e^(1) = y_train - z^(1)

3. Loss terbarui J^(1) ≈ 0,4721

4. Parameter diperbarui kembali melandai searah negatif gradien ∇J.

LAMPIRAN B: VEKTOR BOBOT DAN BIAS AKHIR MODEL ADALINE BEST RUN (RUN 6)

Vektor bobot w dan bias b akhir dari model ADALINE Terstandardisasi (η = 0.1, Epoch 50):

• Bias Akhir (b): +0,1063

• Vektor Bobot Akhir (w):

Fitur	Nama Fitur (x_i)	Bobot Akhir (w_i)
x1	Age	+0,0312
x2	RestingBP	+0,0145
x3	Cholesterol	-0,0781
x4	FastingBS	+0,0812
x5	MaxHR	-0,0645
x6	Oldpeak	+0,1214
x7	Sex_M	+0,1421
x8	ChestPainType_ATA	-0,1854
x9	ChestPainType_NAP	-0,1123
x10	ChestPainType_TA	-0,0214
x11	RestingECG_Normal	-0,0112
x12	RestingECG_ST	+0,0245
x13	ExerciseAngina_Y	+0,1654
x14	ST_Slope_Flat	+0,2145

x15	ST_Slope_Up	-0,3124